

Me n
stand o

DIRECT BUSINESS
IMPACT
Presentations are tools.

CREATIVE CAMPAIGNS
Presentations are tools.

UNIQUE CONCEPTS
Presentations are tools.

RESEARCH



PYTHON DATA SCIENCE MASTERY

La cruda realidad de los proyectos profesionales de Machine Learning

Existen 5 grandes problemas que tenemos que resolver antes de poder aplicar todo lo que ya sabemos sobre modelización

1

LOS DATOS NUNCA ESTARÁN BIEN

2

POSIBLEMENTE NO CONOZCAS LOS DATOS O
EL SECTOR

3

LAS VARIABLES NO SERÁN NUMÉRICAS Y
PERFECTAS

4

TENDRÁS CIENTOS DE VARIABLES

5

(EN CLASIFICACIÓN) EL EVENTO DE INTERÉS
SIEMPRE TENDRÁ MENOS DATOS

1 LOS DATOS NUNCA ESTARÁN BIEN

PROBLEMA

El resultado de nuestro trabajo de machine learning será, como máximo, tan bueno como la calidad de los datos con los que trabajaremos

En la empresa siempre existirán problemas de calidad de datos

EJEMPLO

- Variables con tipo incorrecto pueden llevar a errores
- Con nulos los algoritmos no funcionarán
- Los atípicos pueden sesgar resultados

SOLUCIÓN

- Procesos de calidad de datos para localizar y corregir los problemas antes de hacer nada más



2 POSIBLEMENTE NO CONOZCAS LOS DATOS O EL SECTOR

PROBLEMA

Si no conoces los datos no sabrás qué variables puedes construir, o si tiene sentido que una variable sea o no significativa, etc

Si no conoces el negocio no podrás saber si un dato es erróneo o no podrás valorar los resultados

EJEMPLO

- ¿Puedo incluir el margen como una variable predictiva?
- ¿Puede haber ventas negativas?
- ¿Es normal que solo un 2% de los clientes tengan este producto?

SOLUCIÓN

- Procesos de EDA
- Incorporar a alguien de negocio al proyecto

3

LAS VARIABLES NO SERÁN NUMÉRICAS Y PERFECTAS

PROBLEMA

Scikit learn solo funciona con variables numéricas

Algunos algoritmos piden ciertos requisitos, como distribución normal, etc

Tipos de variables como fechas o texto no se pueden usar directamente

Las variables tendrán diferentes escalas

EJEMPLO

- Me interesa usar variables categóricas ¿cómo puedo hacerlo?
- ¿Cómo puedo predecir con fechas?
- ¿Puedo usar conjuntamente variables como la edad y los ingresos?

SOLUCIÓN

- Procesos de transformación de variables para poder realizar modelización



4 TENDRÁS CIENTOS DE VARIABLES

PROBLEMA

En proyectos reales tendrás cientos o miles de variables candidatas a ser usadas

No queremos descartar ninguna a priori, porque podría ser predictiva

Pero no podemos usar en los modelos (eficiencia y maldición de la dimensionalidad)

EJEMPLO

- Un banco con el que trabajé tenía 5.000 variables en su datamart comercial
- Una aseguradora quería que el modelo fuera sencillo y explicable

SOLUCIÓN

- Técnicas de preselección de variables para identificar ANTES de modelizar las variables que van a resultar predictoras

5

(EN CLASIFICACIÓN) EL EVENTO DE INTERÉS SIEMPRE TENDRÁ MENOS DATOS

PROBLEMA

En la empresa, normalmente el evento de interés tiene menos datos que su complementario

El aprendizaje del modelo puede no ser óptimo simplemente por el peso de cada categoría

EJEMPLO

- El abandono de clientes puede estar sobre el 15%
- La tasa de préstamos no devueltos puede ser del 8%
- El fraude puede ser del 0,01% de las transacciones

SOLUCIÓN

- Métodos de balanceo para conseguir equilibrar la muestra y que el algoritmo capte mejor los patrones