



PYTHON DATA SCIENCE MASTERY

Machine Learning Framework

El desarrollo de un proyecto de Machine Learning se lleva a cabo en 3 grandes fases

Data Scientist

Data Engineer

DESARROLLO

- Importación y Set up
- Calidad datos
- Análisis Exploratorio
- Transformación
- Modelización
- Evaluación

PRODUCCIÓN

- Entrenamiento final de modelo y pipeline
- Limpieza de código
- Código de reentreamiento
- Código de ejecución


PRODUCTIVIZACIÓN

- Batch
- API
- WebApp




Para facilitar tu aprendizaje he organizado toda la metodología en 3 niveles.

Nivel 1: Fases de un proyecto ML



Nivel 2: Métodos y técnicas



Nivel 3: Plantillas de código y recursos de apoyo

- ☐ 01_Plantilla Set Up.ipynb
- ☐ 02_Plantilla Calidad de Datos.ipynb
- ☐ 03_Plantilla EDA.ipynb
- ☐ 04_Plantilla Transformación de datos.ipynb
- ☐ 05_Plantilla Preselección de variables.ipynb
- ☐ 06_Plantilla Balanceo.ipynb

```
import cloudpickle
import numpy as np
import pandas as pd
from janitor import clean_names

ruta_proyecto = 'C:/Users/isaac/Google Drive/DS4B/CursoMachineLearning/
nombre_fichero_datos = 'validacion.csv'
ruta_completa = ruta_proyecto + '/02_Datos/02_Validation/' + nombre_fic
df = pd.read_csv(ruta_completa, index_col=0)
df = clean_names(df) \
    .rename(columns = {'formacion': 'formacion',
                       'prestamo_hipotecario': 'hipoteca',
                       'prestamo_personal': 'consumo'}) \
    .drop_duplicates() \
    .dropna(thresh=1)

variables_finales = ['num_dias_ultimo_contacto',
                     'num_dias_ultimo_contacto',
                     'resultado_campana_anterior',
                     'variacion_tasa_empleo']

df = df[variables_finales]

nombre_pipe_ejecucion = 'pipe_ejecucion.pickle'
```

☐	07_P	NOMBRES	AUTOMATICA	P	X	X	X	X	X
☐	08_P	TIPOS	TIPOS	P	X	X	X	X	X
☐	09_P	NULOS	ELIMINAR REGISTROS	P	X	X	X	X	X
☐	10_P	ATIPICOS	WINSONR MANUAL	P					X
☐	11_C	ENCODING	OE	S			X		
☐	12_C	DISCRETIZACION	DS	S			X		
☐	13_C	BINARIZACION	BIN	S					X
☐	14_C	NORMALIZACION GAUSS	QT	S	X				
☐	15_C	REESCALADO	SS	S	X	X	X	X	X

FASE DE DESARROLLO


Tradicionalmente han existido dos grandes metodologías para la modelización avanzada de datos: CRISP-DM y SEMMA. Aunque cambien los nombres realmente son muy similares. Nosotros utilizaremos una metodología propia a medio camino entre ambas



METODOLOGÍAS TRADICIONALES

METODOLOGÍA CRISP-DM

METODOLOGÍA SEMMA






FASE DE DESARROLLO

La metodología anterior se abre en todo el conjunto de métodos, algoritmos y técnicas que hemos aprendido

Puedes ver el Mindmap cargándolo en la aplicación gratuita:
<https://www.mindmaps.app>



FASE DE DESARROLLO

Te voy a dar todas mis plantillas de desarrollo, que convierten el caos de un proyecto de machine learning en un proceso guiado y sumamente estructurado:

- Reduciendo entre un 50% y un 75% el tiempo de desarrollo
- Minimizando errores
- Estandarizando el proceso

☐  [01_Plantilla Set Up.ipynb](#)☐  [02_Plantilla Calidad de Datos.ipynb](#)☐  [03_Plantilla EDA.ipynb](#)☐  [04_Plantilla Transformacion de datos.ipynb](#)☐  [05_Plantilla Preselección de variables.ipynb](#)☐  [06_Plantilla Balanceo.ipynb](#)☐  [07_Plantilla Modelizacion para Clasificacion.ipynb](#)☐  [08_Plantilla Modelizacion para Regresion.ipynb](#)☐  [09_Plantilla Modelizacion para No Supervisado.ipynb](#)



FASE DE PRODUCCIÓN


El objetivo es seleccionar las versiones finales de los siguientes elementos que hemos usado en desarrollo e incluirlos en un código limpio que usaremos para producción:

- Variables finales que entran en el modelo
- Clases y funciones utilizadas
- Configuraciones y parámetros ajustados
- Mejor algoritmo y su hiperparametrización

Pasar de todo el código de desarrollo

- ☐ 01_Plantilla Set Up.ipynb
- ☐ 02_Plantilla Calidad de Datos.ipynb
- ☐ 03_Plantilla EDA.ipynb
- ☐ 04_Plantilla Transformacion de datos.ipynb
- ☐ 05_Plantilla Preselección de variables.ipynb
- ☐ 06_Plantilla Balanceo.ipynb
- ☐ 07_Plantilla Modelizacion para Clasificacion.ipynb
- ☐ 08_Plantilla Modelizacion para Regresion.ipynb
- ☐ 09_Plantilla Modelizacion para No Supervisado.ipynb

- ☐ 10_Preparacion del codigo de produccion.ipynb



A un código encapsulado en funciones y pipelines para producción

- ☐ 11_Codigo de reentrenamiento.ipynb
- ☐ 12_Codigo de ejecucion.ipynb

```
import cloudpickle
import numpy as np
import pandas as pd
from janitor import clean_names

ruta_proyecto = 'C:/Users/isaac/Google Drive/DS4B/CursoMachineLearningP
nombre_fichero_datos = 'validacion.csv'

ruta_completa = ruta_proyecto + '/02_Datos/02_Validacion/' + nombre_fic

df = pd.read_csv(ruta_completa, index_col=0)

df = clean_names(df) \
    .rename(columns = {'fomacion':'formacion',
                      'prestamo_hipotecario':'hipoteca',
                      'prestamo_personal':'consumo'}) \
    .drop_duplicates() \
    .dropna(thresh=3)

variables_finales = ['euribor3m',
                    'num_dias_ultimo_contacto',
                    'resultado_campana_anterior',
                    'variacion_tasa_empleo']


df = df[variables_finales]

nombre_pipe_ejecucion = 'pipe_ejecucion.pickle'
```

FASE DE PRODUCCIÓN

Este proceso puede ser muy complejo en proyectos reales de gran volumen de datos y variables, así que te voy a enseñar dos recursos que para mí son imprescindibles para hacer proyectos profesionales

Diagrama de flujo del proceso



Matriz de procesos X variables

		TIPO	euribor3m	num_dias_ultimo_contacto	resultado_campana_anterior	variacion_tasa_empleo
NOMBRES	AUTOMATICA	P	X	X	X	X
	TIPOS	P	X			
	DUPLICADOS	P	X	X	X	X
NULOS	ELIMINAR REGISTROS	P	X	X	X	X
NULOS	IMPUTAR MODA	P			X	
ATIPICOS	WINSOR MANUAL	P				X
ENCODING	OE	S			X	
DISCRETIZACION	DS	S		X		
BINARIZACION	BIN	S				X
NORMALIZACION GAUSS	QT	S	X			
REESCALADO	SS	S	X	X	X	X

FASE DE PRODUCCIÓN

Como resultado de la fase de producción generaremos dos códigos

